



M Ű E G Y E T E M 1 7 8 2

Budapesti Műszaki és Gazdaságtudományi Egyetem
Villamosmérnöki és Informatikai Kar
Automatizálási és Alkalmazott Informatikai Tanszék

Deep Learning alapú szótagolás

ÖNNÁLÓ LABORATÓRIUM

Készítette
Németh Gergely Dániel

Konzulens
Ács Judit

2017. május 15.

Abstract

The machine learning paradigm has a strong impact in many fields of science. In this document the author uses the deep learning technology in the hyphenation problems. He shows that the new, neural network based method can learn Liang's standard hyphenation algorithm and give the same results in most times.

The method has been developed for the Hungarian language but it can be implemented in many different languages.

Kivonat

A gépi tanulás felhasználására megnőtt az igény számos tudományterületben. Jelen dokumentumban a szerző a szótagolás problémakörében veti be a deep learning technológia nyújtotta megoldásokat. Megmutatja, hogy a Liang-féle elválasztási módszerek [6] jól közelíthetők egy egyszerű neurális háló segítségével.

Az új elválasztási algoritmus fejlesztése a magyar nyelven történt, azonban a módszer használható számos más nyelv esetén is.

Tartalomjegyzék

1. Bevezetés	3
2. Szótagoló programok	3
2.1. Liang algoritmus	3
2.1.1. Minták választása	4
2.2. Hunspell	4
2.2.1. Magyar eseti elválasztási minták	5
2.2.2. Szótagolási hibák a magyar Hunspellben	5
3. Deep learning alapú módszerek	5
3.1. Deep learning bevezetés	5
3.1.1. Keretrendszerek	5
3.2. Tanító adatok	6
4. A feldolgozás folyamata	6
4.1. Adattisztítás	6
4.2. Adat szűrés	6
4.3. Nyelv osztályozó	7
5. Előreccsatolt neurális háló	7
5.1. Karakter címkézés	7
5.2. Adat-előkészítés	8
5.2.1. Tanítás a karakter környezetéből(ablakozás)	8
5.2.2. Címkézés	8
5.2.3. One-hot kódolás	8
5.2.4. Lapítás	9
5.3. Neurális háló	9
5.4. Tanító-, validációs- és tesztadatok	10
6. Eredmények	11
6.1. Adatszétválasztás	11
6.2. Nyelvfelismerés	11
6.3. Hibás szavak listája	11
6.4. A táblázatokban használt rövidítések	12
Hivatkozások	15

1. Bevezetés

A magyar szavak elválasztását a gyermekek tizenéves korukban elsajátítják. A helyesírás szabályai nyelvünkben egyértelműen definiálják az elválasztás módját [1], melyet hosszas gyakorlás után reflexszerűen tudunk használni és az alpműveltség részeként tekintünk rá.

A magyar elválasztás szerencsére nem környezetfüggő, pusztán a szó ismeretében meg lehet határozni az elválasztását, nem kell a szöveggörnyezetet figyelembe venni. Ezáltal a használt gépi szótagolási eljárások jól használhatóak rá.

A gépi alapú szótagolás jelenleg elválasztási minták illesztésével működik, amelyet a \TeX első kiadása óta fejlesztenek. Az elválasztási módszer elég jó ahhoz, hogy saját minta-szabályok összegyűjtésével a Magyar Tudományos Akadémia Nyelvészeti Intézete az online elválasztási tanácsadó portáljához¹ is ezt használja [7].

A Deep Learning paradigmák előretörésével felmerült az igény a nyelvtechnológiai módszerek mélytanulósos megoldására is. A digitális világban fellelhető számos korpusz megfelelő méretű alappal szolgál a módszerhez szükséges tanító adatok előállításához. A szerző munkája során az elválasztás problémáját vizsgálja meg gépi tanulás szempontjából.

2. Szótagoló programok

Az elterjedt szótagoló algoritmusok kétféle csoportba bonthatóak: szabály- vagy szótagalapúak. A szabad szoftverek világában *de facto* a \TeX szótagolási algoritmusát használják.

A \TeX eredeti szótagoló algoritmusát Prof. Knuth tervezte 1977 nyarán [4]. Ez három fő szótagolási szabályt alkalmazott: 1) utótag leválasztás, 2) előtag leválasztás és 3) magánhangzó - mássalhangzó - mássalhangzó - magánhangzó (vccv) elválasztás, azaz ha ilyen betűnégyes található a szóban, legtöbb esetben a mássalhangzók mentén elválasztható. Ez a három szabály gyakran alkalmazható, azonban már az első algoritmusban kiegészült kisebb szabályokkal („break vowel-q” vagy „break after ck”) és kivételek listájával (300 szó).

A \TeX 82 verzióhoz megjelent Liang szótagoló algoritmus [6], aminek legfontosabb újítása a minta (*patterns*) alapú szótagolás bevezetése volt. Ennek lényege, hogy a szótagolási szabályok mintákra definiálódtak és az algoritmus a szótagolás során ezeket a mintákat keresi a szóban.

A \TeX jelenlegi verziójában a Hunspell szótagoló algoritmust alkalmazzák [8]. Ez az eljárás Liang algoritmusán alapszik, amit nyelvfüggő speciális szótagolási kiterjesztésekkel (*non-standard hyphenation extension*) egészített ki.

2.1. Liang algoritmus

Liang szótagoló algoritmusának alapját a szótagolási minták alkotják [6]. Az algoritmust az angol *hyphenation* elválasztását az alábbi módon végzi:

Az algoritmus először megnézi, hogy a szó benne van-e a kivételek listájában (ez lényegében teljes szavakat tartalmaz mintaként). A *hyphenation* szó nincs a kivételek listájában.

¹Lásd: <http://helyesiras.mta.hu/helyesiras/default/hyph>

Ezután a szó elejére és végére illeszt egy pont jelző karaktert. Ennek jelentősége azoknál a mintáknál lesz, amelyek akkor érvényesülnek, ha a szó elején, vagy a végén szerepelnek.

.hyphenation.

Ezt követően a minták között keres illeszkedést. A *hyphenation* szóra ezek az alábbiak: hy3ph, he2n, hena4, hen5at, lna, n2at, ltio, 2io [6, 37. oldal] A megfelelő mintákat ráillesztve a szóra, a bennük szereplő számokat a szó karakterei közé szűrva az 1. ábrán szereplőket kapjuk.²

```

. h y p h e n a t i o n .
  h y3p h
    h e2n
    h e n a4
    h e n5a t
      l n a
      n2a t
        l t i o
        2 i o
-----
.0h0y3p0h0e2n5a4t2i0o0n0.
  h y-p h e n-a t i o n

```

1. ábra. A *hyphenation* szótagolása

Az algoritmus következő lépésében minden két szomszédos karakter közé illesztünk egy számot. Alapértelmezetten 0-t és ha ennél nagyobb számot találtunk a minta-illesztésnél, a legnagyobb kapott értéket adjuk meg.

A szótagolás szabálya innen már csak egy lépés: a páratlan számok mentén elválasztunk, a párosoknál nem. Ezzel megkaptuk a hy-phen-ation elválasztást.

2.1.1. Minták választása

A fenti algoritmus hatékonyságát nyilvánvalóan a minták mennyisége és hatékonysága határozza meg. Csak azok a szavak választódnak el, amelyekre illeszkedik minta és csak azok lesznek jó elválasztások, melyekre jó minta illeszkedik.

2.2. Hunspell

A Hunspell a T_EX és az OpenOffice jelenleg használt szótagoló algoritmus. A Hunspell Liang algoritmusát egészíti ki Sojka eseti elválasztási algoritmusának [9] olvashatóbb verziójával [8].

A speciális elválasztások felismerése a Liang-féle elválasztási mintákkal történik, melyekhez különféle felüldefiniálási kódokat alkottak. Például a német *Zucker* szót a c1k/k=k minta mentén felismeri, és a definíció alapján *Zuck-ker* módon szótagolja el. A különböző nyelveken számos eseti elválasztási mintát kell definiálni, így ezek a listák a legkülönbözőbb méreteket ölthetik. Az alábbiakban a magyar példát foglaljuk össze.

²Az ábrázolásmód Németh cikkéből származik [8].

2.2.1. Magyar eseti elválasztási minták

A betűkettőzéssel jelölt többjegyű hosszú mássalhangzókat elválasztás nélkül szó közepén a csak az első karakter kettőzésével jelöljük, azonban elválasztáskor külön-külön kiírjuk mindkét többjegyű mássalhangzót: pl. *ssz*, *sz-sz* vagy *ccs*, *cs-cs*. A klasszikus példa: *asz-szony-nyal*

A nehézséget az okozza, hogy előfordulhat az is, hogy az első betű egy egyjegyű és ekkor fel kell ismerni, hogy kell-e kettőzni vagy sem(pl. *meg-gyúj-tot-ta*).

2.2.2. Szótagolási hibák a magyar Hunspellben

A leggyakoribb elválasztási hibák abból a tényből fakadnak, hogy a hunspell tervezői a tördelési szempontokat vették figyelembe, és így a rövid (egyetűs) kezdő és záró szótagokat letiltották. Ám ez, például összetett szavak esetében, azt eredményezte, hogy sokszor a szó közepén is több magánhangzóból álló szótagok jelentek meg.

Hunspell szótagolása:

au-tó-val
szem-üveg-gel
has-izom
messze

Helyesen:

au-u-tó-val
szem-ü-veg-gel
has-i-zom
mesz-sze

3. Deep learning alapú módszerek

3.1. Deep learning bevezetés

A gépi tanulás területén egyre nagyobb teret nyernek a deep learning alapú módszerek. A hagyományos osztályozási feladatokon túl, szekvenciális, ún. taggelési problémák megoldására is alkalmasak a neurális hálók, különös tekintettel a rekurrens neurális hálókra.

A mély tanulás bevetését a nyelvtechnológia területén az a tény élteti, hogy az elektronikus kommunikáció korában jelentős mennyiségű nyelvi adatbázisok állnak rendelkezésünkre, így a deep learning legfontosabb eleme, a megfelelő méretű tanulmányadat elérhető. Az ismertetett elválasztási algoritmusok kulcseleme, hogy megfelelő elválasztási mintákat ismerjünk fel az adathalmazon (*korpusz*). A képfelismerés terén sokkal komplexebb minták megtalálásában is jelentős eredményeket értek el a deep learning segítségével, így e módszer bevetése a szótagolás problémakörében megalapozott.

3.1.1. Keretrendszerek

Deep learning rendszerek tervezésénél az utóbbi időben ipari és kutatói területen egyaránt elterjedően vannak a magas szintű keretrendszerek. Ezek legnagyobb előnye, hogy az aktív fejlesztői közösség a gyorsan fejlődő tudományág eredményeit alkalmazható technológiákként tárja a felhasználók elé. A jelentősebb keretrendszerek: TensorFlow³, Torch7⁴, Keras⁵. Az itt ismertetett eljárások megvalósításához a Keras nyújtotta lehetőségekkel valósultak meg [2].

³TensorFlow: <https://www.tensorflow.org/>

⁴Torch7: <http://torch.ch/>

⁵Keras: <https://keras.io/>


3.2. Tanító adatok

Mély tanulás esetén az eredmény minőségét alapvetően meghatározza a tanítóhalmaz minősége. Jelen esetben a korpuszok és azok megfelelő szótagoltsága.

A hálótervezés során a Magyar Webkorpusz leggyakoribb 100000 szaván kísérleteztünk [3, 5].

4. A feldolgozás folyamata

A szótagoló jelenleg magyar nyelvre van tervezve, azonban az eljárás lényege univerzális. A nyelvosztályozás jelenleg csak angol szavak szűrését jelenti. Az eredményekben, ahol nem térek ki rá, nem használtam.



2. ábra. A feldolgozás folyamata

4.1. Adattisztítás

Az adatfeldolgozás során az alábbi tisztítási eljárásokat végeztem:

kisbetűsítés A karaktereket kisbetűssé tettem.

speciális karakter szűrés Az alábbi speciális karaktereket töröltem a szövegből (a `python string.punctuation` környezetfüggően választja meg ezeket, így máshol eltérhetnek): `!"#$%&'()*+,-./:;<=>?@[\\]^_`{|}~`

szám szűrés A szövegben található számokat töröltem.

Majd a szavakat egyedivé tettem (egy számlálóban eltárolva az előfordulási gyakoriságot).

4.2. Adat szűrés

A háló sajnos nem minden előforduló esetet tud kezelni, így a későbbi implementálásig ezeket szűröm.

Speciális karakterek: az adott nyelvre nem jellemző karakterek bezavarhatnak a tanításba, így ezeket célszerű kivenni. A magyar elválasztó esetén csak a magyar ábécé betűit hagytam meg.

Kettős betűk: az osztályozó jellegéből adódóan a plusz karakter bevonásával képződő elválasztást (például a `ssz`-ből `sz-sz`) a hálón kívül dolgozom fel.

4.3. Nyelv osztályozó

A tanítások kiértékelése során arra a következtetésre jutottam, hogy a hunspell és az én elválasztóm közötti eltérések jelentős része akkor adódik, ha idegen nyelvű szót próbálunk meg elválasztani. Így az elválasztó javításának érdekében egy nyelv osztályozót is bevezettem.

A jelenlegi nyelvválasztó egy egyszerű bigram gyakoriság alapú osztályozó. Az osztályozó azon alapszik, hogy a nyelvekre jellemző, hogy mely karakterkettősök (bigramok) fordulnak elő leggyakrabban bennük. Az osztályozó szótárát három-három Wikipédia cikk képi, azaz pár ezer szó. Ezek alapján kiválasztjuk a leggyakoribb bigramokat és ezzel vetjük össze a vizsgálandó szót.

A szóban megszámláljuk az összes bigramot és összevetjük, hogy az egyes nyelvek listájából hány szerepel benne. Így kapunk egy-egy 0-1 közötti számot, amit értelmezhetünk úgy, mint annak a valószínűsége, hogy a szó az adott nyelvből származik. Amennyiben egy nyelv a többihez képest kimagaslóan jól teljesített, akkor azt mondhatjuk, hogy a szó nagy valószínűséggel abból a nyelvből származik.

Mivel az angol szavakat szerettem volna kiszűrni, úgy állítottam be a küszöbértéket, hogy minimalizáljam a kiesett magyar szavakat, azaz csak akkor dobjon el egy szót, ha nagyon biztos abban, hogy az angol.

Ha 0,60-as különbséget várunk el az osztályozótól, a vizsgált kb. 100000 egyedi szóból 571-et jelöl meg angolnak, amiből 46-nak van értelmes magyar jelentése (többek között a *perc*, *citrom*, *hierarchia* alakjai).

5. Előrecsatolt neurális háló

A neurális háló lényege ebben az esetben az, hogy a szó minden karakterére eldöntsük a környezetében lévő karakterek segítségével, hogy a karakternél van-e elválasztás.

A szavakat minden karakter mentén felbontjuk az adott ablakméretre, majd ezekre az ablakokra tanítva oldunk meg egy osztályozó problémát, ami ad egy címkét a karakternek és a címke alapján végezzük az elválasztást.

5.1. Karakter címkézés

Kétféle címkézést használunk. Az első eset előnye, hogy több címke van így több információt adunk át a modellnek, a másodiké pedig, hogy a jóslat címkézés minden esetben elválasztássá alakítható. Ez a BMES esetében nem teljesül: ha két karakterre egymás után E-t jósol, az nem alakítható rögtön valós elválasztássá.

A jelenlegi munkában a BM címkézést elemeztük.

BMES

- B: Begin, szótag elején álló karakter
- M: Middle, közepén lévő karakter, se előtte, se utána nincs elválasztás
- E: End, a karakter után elválasztás van
- S: Single, egy karakterből álló szótag

A le-o-párd szó címkézése: BESBMMME

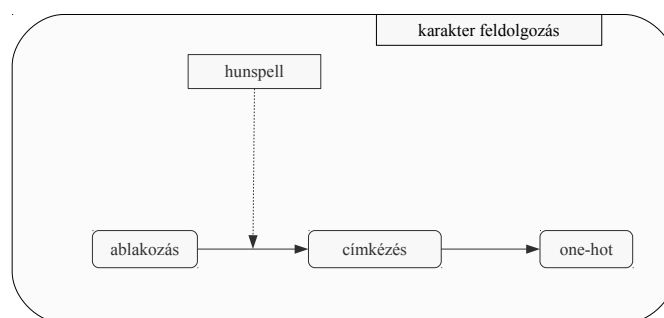
BM

- B: Begin, szótag elején álló karakter
- M: Minden egyéb eset

A *le-o-párd* szó címkézése: BMBBMMM

5.2. Adat-előkészítés

A 3. ábrán láthatjuk a tanítóadat előállításának módját. Az alábbiakban egy példa alapján végigmegyünk a lépéseken.



3. ábra. Tanítóadat előállítása

Ha az *leopárd* szó *o* karakterét szeretnénk egy 5-ös szimmetrikus ablakú környezetben tanítóadatnak előkészíteni, **BM** címkézéssel, akkor az alábbi előkészületeket kell tennünk:

5.2.1. Tanítás a karakter környezetéből(ablakozás)

A jelölésrendszer alapján az 5-ös szimmetrikus ablak azt jelenti, hogy a karakter előtt és a karakter után is két-két további karaktert veszünk, és ez alapján az öt karakter alapján próbáljuk meg eldönteni, milyen címke illeszkedik a középső karakterre. Ezt jelöljük *2-1-2*-vel. Az *leopárd* szó és az *o* betű esetén ez *le o pá* ablakot jelent.

Ha az ablak túlnyúl a szó szélén, az elterjedt jelölés alapján a szó elején \wedge karaktereket, illetve a szó végén további $\$$ karaktereket illesztünk az ablakba.

5.2.2. Címkézés

Az 5.1. fejezetben ismertetett címkézési eljárással az ablakhoz hozzárendelünk egy címkét. A *le o pá* esetén az *o* betű egy szótag kezdete, így a **BM** címkézés esetén *B* címkét kap.

5.2.3. One-hot kódolás

Ahhoz, hogy a karakterekből a keras által feldolgozható tanítóadat legyen, one-hot kódolást végzünk rajta.

A karakterek esetében ez azt jelenti, hogy a megengedett karaktereket, jelen esetben a magyar ábécé karaktereit és a kezdő-, befejezőkaraktereket egymás után felsoroljuk,

majd az adott karaktert úgy reprezentáljuk, hogy egy ezzel azonos hosszúságú tömbben a karakternek megfelelő sorszámu helyre egyest, minden további mezőbe nullást írunk.

A **BM** illetve **BMES** címkézést ugyanígy reprezentáljuk egy 2 avagy 4 hosszú tömbbel.

5.2.4. Lapítás

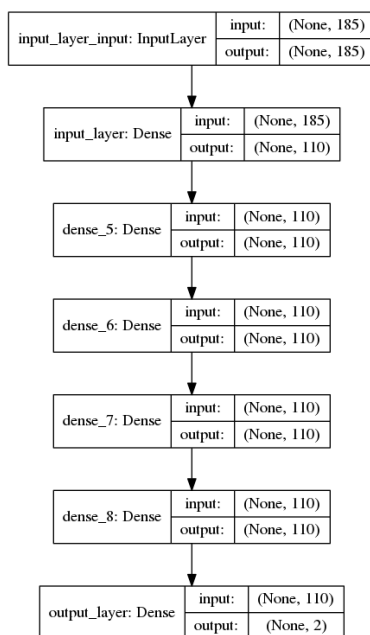
Ha a fentieket elvégezzük egy 5 hosszú ablakra, akkor a magyar ábécét figyelembe véve 5 darab $35 + 2$ hosszú tömböt kapunk. A háló bemenetét úgy kapjuk meg, hogy ezt ellapítjuk egy $5 \cdot 37$ hosszú tömbbé (amiben 5 helyen 1-es, minden további helyen 0-ás szerepel). Ez lesz a tanítóadatunk.

Vagyis a háló bemenete a *le o pá* ablakot reprezentáló 185 hosszú $\{0, 1\}$ tömb, az elvárt kimenet pedig a *B*-t reprezentáló 1-es.

5.3. Neurális háló

Egy egyszerű előre csatolt neurális hálót használtam, ahol a rejtett rétegek számát és a rétegek méretét optimalizálás után kaptam (lásd: a 3. táblázat).

A már megismert 5-ös ablakra a 4. ábrán látható modell vizualizációt szolgáltatja a Keras.⁶ A tanítás során *sigmoid* aktivációs függvényt és *adam* optimalizációt használtam.




4. ábra. A háló modellje

⁶A None réteg azt jelenti, hogy a háló képes több dimenziót fogadni. Lásd bővebben: <https://github.com/fchollet/keras/issues/2054>

5.4. Tanító-, validációs- és tesztadatok


Az tanítóadatok előállítás módját immár ismertettük. Azonban a deep learning technikákhoz még át kell tekintenünk a következőt: a neurális hálót egy ún. tanító adathalmazon szokás tanítani. A tanítás eredményességét egy ún. validációs adathalmaz alapján ellenőrizzük minden tanítási lépés során. A tanítás megállításának lépését is ez alapján határozzuk meg. Végül, az elkészült, betanult háló eredményességét az ún. teszt adatokon teszteljük.

Mit is jelent ez számunkra? Az első, laikus (és így a legtöbb teszten futtatott) megoldást az 5. ábrán láthatjuk. Ebben a korpuszból származó egyedi szavakat először alávetettük a már ismertetett tanítóadat generáló eljárásnak, majd a kapott be- és kimeneti tömböket megkeverjük és felosztjuk a három adattömbre. Példánkban 70-20-10 arányban.




5. ábra. A kezdeti adatgenerálás

Azonban az adathalmazok függetlenségét ez a megoldás sérti. Mégpedig kétféleképp: az egyik eset, hogy az adatok karakterenként vannak szétválasztva, így előfordulhat, hogy nincs olyan szó, ami egyben szerepelne valamelyik halmazban. Erre szolgál megoldásként a 6. ábrán látható eljárás. Ekkor a halmazok szétválasztása a szavak szintjén történik, majd csak ez után generálódik le a tényleges be-, illetve kimenet.



6. ábra. Egyedi szavak felosztása

A másik probléma a tanítóadatok egyediségében rejlik. Ha egy ablak két szóban is szerepelt, akkor az adathalmazban kétszer fog szerepelni. Ezért a 7. ábra alapján először előállítódik a be-, kimenet, majd ezeket egyedivé tesszük. Ezután megkeverhetjük, és szétválaszthatjuk a három adathalmazra. Ennek az eljárásnak az előnye, hogy ekkor a teszt adatok ténylegesen függetlenek a tanító és validációs adatoktól, a hátránya viszont, hogy nem reprezentálja az ablakok előfordulását. Ha az *abcd^f* ablak általában *c*-nél elválaszt, de van olyan szó, amiben nem, akkor mindkettőnek azonos lesz a súlya (és ha az egyik a tanító, a másik a teszt adathalmazba fog kerülni, ez utóbbi a jó tanulás esetén hibát fog jelezni).



7. ábra. Egyedi adatok

6. Eredmények

Az első tanítások eredményei a 2. táblázatban láthatóak.

A 3. táblázat a hiperparaméterek optimalizálási eredményeit foglalja össze. Itt a 2-1-2 környezetű karakter-címkézés 2-10 rétegű, rétegenként 10-100 neuronú tanítások közül láthatjuk azokat, amelyeknek validációs hibája megközelíti a 4 százalékot.

A 4. táblázat a karakter címkézéséhez a körülötte megvizsgált karakterek számát (ablak méretét) változtattuk. Jól látható, hogy egy-egy karakter bevétele még jóval kevesebb információt árul el a címkézésről, mint a többi. Hasonlóképp észrevehető, hogy a túl nagy ablak is ront a helyzeten. Ez azért jelenik meg, mivel a nagyobb ablakok bevezetésével egyre ritkábbak lesznek az adott típusú minták előfordulása az adatokban.

Az 5. táblázatban a 3-1-3 ablak hiperparamétereit láthatjuk, itt már a Precision, Recall és Fscore értékekkel számolva.

6.1. Adatszétválasztás

Az 5.4. fejezetben ismertetett háromféle adatszétválasztási módszer különbségei: A

	Valid_loss	Precision	Recall	Fscore
Original:	0.0372933148901	0.984795679981617	0.9884297520661157	0.98660936960442
Unique words:	0.0382063584876	0.9851730446714438	0.9877331091409355	0.9864514159224487
Unique chars:	0.0836893673412	0.9652839948274147	0.9608872165560947	0.9630805875347359

1. táblázat. Adat egyediség

karakter egyediségről elmondható, hogy többet hibázik, főként az összetett szavak szótagolásánál.

6.2. Nyelvfelismerés

A jelenleg beiktatott nyelvfelismerő nem változtatott sokat az értékeken. Mivel csak részben szűrte ki az angol szavakat, ezzel csak csökkentette az angol szavakra való tanulás esélyét, így a bent maradt szavak súlyosabb hibát eredményeztek.

6.3. Hibás szavak listája

Az alábbi listában 400 a tanításban nem szereplő szóra való szótagolás hibás szavai szerepelnek. Ebben a tanításban, és a 400 szó kiválogatásakor használtuk a bigram nyelvfelismerőt. A 400 szóból 16 esetében tért el a szótagolónk a Hunspellétől (4%):

A modell szótagolása:

fre-u-de
áram-k-i-ma-ra-dás
gyer-me-k-ott-hon
hú-gyúti
mui-to
attrak-ció
li-ech-tens-tein
hauser
has-i-zom
elől-há-tul
cadre
sho-ulders
so-ci-a-le
há-ny-in-gert
va-luták
exp-res-sing

A Hunspell által adott cél:

freu-de
áram-ki-ma-ra-dás
gyer-mek-ott-hon
húgy-úti
mu-i-to
att-rak-ció
liech-tens-tein
ha-user
has-izom
el-öl-há-tul
cad-re
sho-ul-ders
so-ci-ale
hány-in-gert
va-lu-ták
exp-r-es-sing

Mint láthatjuk, továbbra is jelentős részben az idegen szavak okoznak eltérést, azonban szeretném kiemelni a *has-i-zom* és a *so-ci-a-le* szótagolásokat, ahol az egy szótagban több magánhangzót tartalmazó eredeti szótagolás helyett szótagonként egyet tartalmazót adott a modellünk.

6.4. A táblázatokban használt rövidítések

- Length: $a-l-b$ a vizsgált karakter előtt a utána b karaktert veszünk be környezébe, ami alapján a címkézést végezzük.
- Tag: a címkézés BM vagy BMES
- NLayer, NL: a háló rejtett rétegeinek száma
- NHidden, NH: a rejtett rétegek mérete
- Val_loss: a validációs adatok binary(BM) illetve categorical(BMES) crossentropy hibafüggvénnyel számolt hibája
- Test_w: maximumkiválasztás után hibás eredményt adó teszt adatok száma
- Epochs, Ep.s: a tanításhoz szükséges epoch-ok száma. A tanítás végét early stoping módszerrel határoztuk meg.

No	Tag	Length	Loss	Batch size	Val_loss	Epochs
1	BMES	2-1-0	cat_cross	512	0.616	483
2	BM	2-1-0	bin_cross	1024	0.262	475
3	BM	2-1-0	cat_cross	1024	0.261	543
4	BM	2-1-1	bin_cross	1024	0.063	247
5	BM	2-1-2	bin_cross	1024	0.050	213
6	BM	3-1-3	bin_cross	1024	0.047	223
7	BMES	2-1-2	cat_cross	1024	0.107	389
8	BMES	3-1-3	cat_cross	1024	0.090	769

2. táblázat. Előrecsatolt háló tanítása különböző paraméterekkel

No	Tag	Length	NLayer	NHidden	Epochs	Val_loss	Test_w
2.1	BM	2-1-2	2	10	308	0.05025	0.01568
2.2	BM	2-1-2	2	20	250	0.04454	0.01352
2.3	BM	2-1-2	2	30	189	0.04274	0.01264
2.4	BM	2-1-2	2	40	170	0.04151	0.01185
2.5	BM	2-1-2	2	50	196	0.04207	0.01129
2.6	BM	2-1-2	2	60	167	0.04068	0.01119
2.7	BM	2-1-2	2	70	166	0.04155	0.01122
2.8	BM	2-1-2	2	80	175	0.03994	0.01073
2.9	BM	2-1-2	2	90	179	0.03962	0.01050
2.10	BM	2-1-2	2	100	145	0.03911	0.01100
3.7	BM	2-1-2	3	70	176	0.04221	0.01155
3.8	BM	2-1-2	3	80	161	0.03881	0.01095
3.9	BM	2-1-2	3	90	171	0.03872	0.01037
3.10	BM	2-1-2	3	100	178	0.03886	0.01062
4.7	BM	2-1-2	4	70	208	0.04024	0.01116
4.8	BM	2-1-2	4	80	171	0.03995	0.01077
4.9	BM	2-1-2	4	90	177	0.03894	0.01077
4.10	BM	2-1-2	4	100	177	0.03885	0.01090
5.4	BM	2-1-2	5	40	199	0.04423	0.01225
5.5	BM	2-1-2	5	50	205	0.03992	0.01136
5.6	BM	2-1-2	5	60	220	0.03955	0.01090
5.7	BM	2-1-2	5	70	179	0.04013	0.01063
5.8	BM	2-1-2	5	80	207	0.03937	0.01032
5.9	BM	2-1-2	5	90	218	0.03995	0.01076
5.10	BM	2-1-2	5	100	186	0.03927	0.01092
6.7	BM	2-1-2	6	70	202	0.04186	0.01149
6.8	BM	2-1-2	6	80	218	0.04048	0.01076
6.9	BM	2-1-2	6	90	157	0.04715	0.01221
6.10	BM	2-1-2	6	100	217	0.03926	0.01072
7.7	BM	2-1-2	7	70	254	0.04432	0.01218
7.8	BM	2-1-2	7	80	221	0.04335	0.01169
7.9	BM	2-1-2	7	90	224	0.03943	0.01046
7.10	BM	2-1-2	7	100	210	0.04165	0.01198

3. táblázat. Hiperparaméter optimalizálás (2-1-2)

No	Tag	Length	NLayer	NHidden	Epochs	Val_loss	Test_w
3.6	BM	1-1-1	5	60	303	0.09159	0.03617
3.7	BM	1-1-1	5	70	303	0.09156	0.03634
3.8	BM	1-1-1	5	80	229	0.09155	0.03582
3.9	BM	1-1-1	5	90	252	0.09137	0.03544
3.10	BM	1-1-1	5	100	196	0.09281	0.03595
3.11	BM	1-1-1	5	110	249	0.09129	0.03601
5.6	BM	2-1-2	5	60	222	0.04062	0.01113
5.7	BM	2-1-2	5	70	202	0.03969	0.01069
5.8	BM	2-1-2	5	80	222	0.04209	0.01099
5.9	BM	2-1-2	5	90	214	0.03992	0.01070
5.10	BM	2-1-2	5	100	198	0.03950	0.01049
5.11	BM	2-1-2	5	110	190	0.03995	0.01052
7.6	BM	3-1-3	5	60	133	0.03853	0.00988
7.7	BM	3-1-3	5	70	131	0.04250	0.01096
7.8	BM	3-1-3	5	80	147	0.04433	0.01245
7.9	BM	3-1-3	5	90	149	0.03865	0.00982
7.10	BM	3-1-3	5	100	137	0.03813	0.00972
7.11	BM	3-1-3	5	110	136	0.03926	0.00952
9.6	BM	4-1-4	5	60	121	0.03903	0.01005
9.7	BM	4-1-4	5	70	119	0.04316	0.01143
9.8	BM	4-1-4	5	80	125	0.04126	0.01104
9.9	BM	4-1-4	5	90	118	0.03934	0.01052
9.10	BM	4-1-4	5	100	116	0.03831	0.01072
9.11	BM	4-1-4	5	110	126	0.03967	0.01082
11.6	BM	5-1-5	5	60	112	0.04542	0.01183
11.7	BM	5-1-5	5	70	111	0.04082	0.01087
11.8	BM	5-1-5	5	80	119	0.04566	0.01220
11.9	BM	5-1-5	5	90	99	0.04360	0.01005
11.10	BM	5-1-5	5	100	103	0.04013	0.01035
11.11	BM	5-1-5	5	110	98	0.04117	0.01064

4. táblázat. Karakter-környezet ablak méretének optimalizálása

No	Length	NL	NH	Ep.s	Val_loss	Precision	Recall	Fscore
5.6	3-1-3	5	60	143	0.03939	99.247	99.022	99.134
5.8	3-1-3	5	80	149	0.03716	99.275	99.107	99.191
5.9	3-1-3	5	90	147	0.03765	99.213	99.070	99.142
5.10	3-1-3	5	100	148	0.03783	99.311	99.164	99.238
5.11	3-1-3	5	110	146	0.03756	99.279	99.107	99.193
5.12	3-1-3	5	120	128	0.03571	99.369	98.977	99.173
5.13	3-1-3	5	130	124	0.03793	99.406	98.965	99.185
6.6	3-1-3	6	60	165	0.03982	99.193	99.121	99.157
6.7	3-1-3	6	70	162	0.03967	99.294	98.931	99.112
6.12	3-1-3	6	120	145	0.03844	99.293	99.116	99.204
6.13	3-1-3	6	130	145	0.03729	99.274	99.057	99.165
7.9	3-1-3	7	90	187	0.03963	99.285	99.004	99.144
7.10	3-1-3	7	100	151	0.03708	99.259	99.200	99.230
7.12	3-1-3	7	120	139	0.03776	99.271	99.173	99.222

5. táblázat. Hiperparaméter-optimalizálás (3-1-3)

Hivatkozások

- [1] Magyar Tudományos Akadémia and Mad'arsko Budapest'. *A magyar helyesírás szabályai*. Akadémiai kiadó, 1959.
- [2] François Chollet. Keras, 2015.
- [3] Péter Halácsy, András Kornai, Nemeth Laszlo, Rung Andras, István Szakadát, and Tron Viktor. Creating open language resources for hungarian. 2004.
- [4] Donald Ervin Knuth. *TEX and METAFONT: New directions in typesetting*. American Mathematical Society, 1979.
- [5] András Kornai, Péter Halácsy, Viktor Nagy, Csaba Oravecz, Viktor Trón, and Dániel Varga. Web-based frequency dictionaries for medium density languages. In *Proceedings of the 2nd International Workshop on Web as Corpus*, pages 1–8. Association for Computational Linguistics, 2006.
- [6] Franklin Mark Liang. *Word hyphenation by computer*. Department of Computer Science, Stanford University, 1983.
- [7] Márton Miháltz, Péter Hussami, Zsófia Ludányi, Iván Mittelholtz, Ágoston Nagy, Csaba Oravecz, Tibor Pintér, and Dávid Takács. Helyesírás. hu. 2013.
- [8] László Németh. Automatic non-standard hyphenation in openoffice. org. *COMMUNICATIONS OF THE TEX USERS GROUP TUGBOAT EDITOR BARBARA BEETON PROCEEDINGS EDITOR KARL BERRY*, page 32, 2006.
- [9] Petr Sojka et al. Notes on compound word hyphenation in tex. *TUGboat*, 16(3):290–296, 1995.